


SOLUCIONARIO DEL LIBRO ESTADÍSTICA Y PROBABILIDAD



**HELBERT JUSTO LUQUE
ZEVALLOS**

Estadística y Probabilidad (Solucionario)

Autor:
Luque Zevallos Helbert Justo

Editor a través de amazon.com
Independently published
Disponible en <https://www.amazon.com>

**Prohibida la reproducción total o parcial de
esta obra**

DERECHOS RESERVADOS

País de origen: PERÚ
Idioma: Español

ISBN:9798310697546



Chapter 1 Presentación

Este solucionario ha sido concebido como una herramienta complementaria para los estudiantes y docentes que emplean el texto principal *Estadística y Probabilidad: Fundamentos y Aplicaciones Prácticas*. Su propósito central es proporcionar una guía detallada y estructurada que permita comprender y resolver los ejercicios planteados en el libro, enfatizando tanto la obtención de resultados como el análisis riguroso de los conceptos fundamentales involucrados.

El solucionario sigue la misma estructura temática del libro, lo que facilita una navegación fluida entre la teoría y la práctica. Cada ejercicio es abordado con un enfoque pedagógico que prioriza la claridad y precisión, asegurando que incluso los temas más complejos puedan ser comprendidos progresivamente. Se incluyen explicaciones detalladas en cada solución, permitiendo que el lector no solo llegue a la respuesta correcta, sino que también desarrolle habilidades analíticas esenciales en el campo de la estadística y la probabilidad.

Entre los temas tratados se encuentran la estadística descriptiva, las técnicas de muestreo, la teoría de probabilidades, las distribuciones de probabilidad y el análisis bivariado. Cada uno de estos capítulos presenta ejercicios con soluciones desarrolladas paso a paso, destacando la aplicación de métodos estadísticos en contextos reales y promoviendo un aprendizaje integral y significativo.

El libro *Estadística y Probabilidad: Fundamentos y Aplicaciones Prácticas* abarca un amplio espectro de herramientas estadísticas esenciales para el análisis de datos. Este solucionario amplía dicha experiencia al permitir a los estudiantes validar su comprensión mediante la práctica y la resolución efectiva de problemas. Al utilizar ambos recursos en conjunto, los lectores

podrán consolidar sus conocimientos y fortalecer su confianza en el manejo de técnicas estadísticas.

Agradezco a los estudiantes, docentes e investigadores que encuentran en este material un recurso valioso para su formación académica y profesional. Espero que este solucionario sirva como un puente entre la teoría y la práctica, inspirando a los lectores a explorar la estadística con curiosidad, rigor y entusiasmo. Mi objetivo es que este esfuerzo contribuya significativamente al desarrollo de una sólida base estadística aplicable tanto en el ámbito académico como profesional.

Finalmente, invito a los lectores a continuar explorando el contenido del libro principal, *Estadística y Probabilidad: Fundamentos y Aplicaciones Prácticas*, y a utilizar este solucionario como una herramienta de apoyo para maximizar su aprendizaje. La relación entre estos dos recursos está diseñada para garantizar que cada lector pueda enfrentar con éxito los desafíos estadísticos y disfrutar del proceso de descubrimiento en esta disciplina.

Helbert Justo Luque Zevallos

Estadística y Probabilidad

Helbert Justo Luque Zevallos

2025

Contents

1	Presentación	3
I	Fundamentos de la Estadística	5
1	Estadística Descriptiva	7
1.1	Ejercicios Propuestos	7
1.1.1	Definición de Estadística, Población, Muestra, Parámetro, Estadístico	7
1.1.2	Variables estadísticas: Clasificación y Etapas de una Investigación	13
1.1.3	Organización y Presentación de Datos	18
1.1.4	Medidas de Posición	25
1.1.5	Medidas de Dispersión	31
1.1.6	Medidas de Deformación: Asimetría y Curtosis	38
1.1.7	Diagrama de Caja (Box Plot)	48
2	Técnicas de Muestreo	59
1.1	Ejercicios Propuestos	59
1.1.1	Introducción a la Teoría del Muestreo	59
1.1.2	Muestreo Aleatorio	67
1.1.3	Muestreo Aleatorio Estratificado	75
1.1.4	Muestreo Aleatorio por Conglomerado	83

II	Probabilidad y Distribuciones	93
3	Teoría de Probabilidades	95
1.1	Ejercicios Propuestos	95
1.1.1	Principios de Conteo	95
1.1.2	Experimento Aleatorio, Espacio Muestral y Eventos	104
1.1.3	Probabilidad de un Evento	112
1.1.4	Probabilidad Condicional y Regla de Multiplicación .	118
4	Distribuciones de Probabilidad	127
1.1	Ejercicios Propuestos	127
1.1.1	Modelos de Distribución Discreta	127
1.1.2	Modelos de Distribución Continua	143
III	Análisis Bivariado y Variables Aleatorias	161
5	Distribuciones Bivariadas	163
1.1	Ejercicios Propuestos	163
1.1.1	Tablas Estadísticas Bidimensionales	163
1.1.2	Distribuciones Marginales	183
1.1.3	Covarianza y Distribuciones Condicionales	202
6	Variable Aleatoria	221
1.1	Ejercicios Propuestos	221
1.1.1	Variable Aleatoria Discreta	221
1.1.2	Variable Aleatoria Continua	235
1.1.3	Propiedades de las Variables Aleatorias	243

Parte I

Fundamentos de la Estadística

Chapter 1 Estadística Descriptiva

1.1 Ejercicios Propuestos

1.1.1 Definición de Estadística, Población, Muestra, Parámetro, Estadístico

Exercise 1.1

Define la estadística y explica su importancia en la toma de decisiones.

Proof. La **estadística** es la rama de las matemáticas que se encarga de recolectar, organizar, analizar, interpretar y presentar datos. Su importancia en la toma de decisiones radica en que permite transformar datos crudos en información valiosa y comprensible. Esto facilita:

- ❁ **Identificar tendencias y patrones:** Permite reconocer comportamientos o cambios en una variable de interés.
- ❁ **Tomar decisiones fundamentadas:** Ofrece una base cuantitativa para evaluar diferentes opciones y estrategias en campos como la economía, la salud, la ingeniería, entre otros.
- ❁ **Realizar predicciones:** A través de técnicas inferenciales, es posible estimar valores futuros o evaluar el impacto de ciertas variables.
- ❁ **Optimizar recursos:** Ayuda a evaluar la eficiencia de procesos y la efectividad de políticas o intervenciones.



Exercise 1.2

Distingue entre una población y una muestra, utilizando un ejemplo relacionado con una encuesta de salud.

Proof. Una **población** es el conjunto completo de elementos u observaciones

1.1. EJERCICIOS PROPUESTOS CHAPTER 1. ESTADÍSTICA DESCRIPTIVA

que comparten ciertas características. Por ejemplo, en una encuesta de salud, la población podría ser *todos los habitantes de una ciudad*.

Una **muestra** es un subconjunto representativo de la población, seleccionado para realizar el estudio, especialmente cuando encuestar a toda la población es inviable por cuestiones de costo o logística. Por ejemplo, se podría seleccionar una muestra de *1,000 ciudadanos* para inferir conclusiones sobre el estado de salud general. ■

Exercise 1.3

Describe qué es un parámetro poblacional y un estadístico muestral, y da ejemplos de cada uno.

Proof. Un **parámetro poblacional** es una medida numérica que resume una característica de toda la población. Por ejemplo, la *media de ingresos* de todos los hogares de un país es un parámetro poblacional.

Un **estadístico muestral** es una medida calculada a partir de una muestra, la cual se utiliza para estimar el parámetro poblacional. Por ejemplo, la *media de ingresos* obtenida al analizar una muestra de 500 hogares es un estadístico muestral. ■

Exercise 1.4

Explica la diferencia entre estadística descriptiva y estadística inferencial.

Proof. La **estadística descriptiva** se ocupa de resumir y describir las características de un conjunto de datos mediante medidas como la media, la mediana, la moda, la desviación estándar, y a través de representaciones gráficas como tablas y gráficos. Por ejemplo, calcular y representar la distribución de edades en un grupo de estudiantes.

La **estadística inferencial** permite hacer generalizaciones o inferencias sobre una población basándose en datos obtenidos de una muestra. Utiliza

técnicas como intervalos de confianza y pruebas de hipótesis. Por ejemplo, estimar la proporción de votantes a favor de una propuesta en toda la población, basándose en una encuesta a una muestra representativa. ■

Exercise 1.5

Describe una situación en la que sería más adecuado trabajar con una muestra en lugar de con la población completa.

Proof. Cuando la población es muy grande o de difícil acceso, trabajar con una muestra es más adecuado. Por ejemplo, en el análisis de la **satisfacción de clientes de una cadena de supermercados** que cuenta con millones de clientes, encuestar a todos sería impracticable. Por ello, se selecciona una muestra representativa de clientes para obtener conclusiones que, con un margen de error aceptable, se puedan extrapolar a toda la población. ■

Exercise 1.6

Define el concepto de muestreo y nombra al menos tres tipos de muestreo utilizados en estadística.

Proof. El **muestreo** es el proceso de seleccionar un subconjunto de individuos u observaciones de una población con el fin de estudiar sus características y realizar inferencias sobre la población completa.

Tres tipos comunes de muestreo son:

1. **Muestreo aleatorio simple:** Cada individuo de la población tiene la misma probabilidad de ser seleccionado.
2. **Muestreo estratificado:** La población se divide en grupos homogéneos (estratos) y se extrae una muestra de cada grupo.
3. **Muestreo por conglomerados:** La población se divide en grupos o conglomerados, se seleccionan aleatoriamente algunos de estos grupos, y luego se estudian todos o parte de los elementos de los conglomerados selec-

Chapter 2 Técnicas de Muestreo

1.1 Ejercicios Propuestos

1.1.1 Introducción a la Teoría del Muestreo

Exercise 2.1

Demuestra que el error de muestreo disminuye al aumentar el tamaño de la muestra en un muestreo aleatorio simple.

Proof. Sea σ^2 la varianza de la población. En un muestreo aleatorio simple, el estimador de la media muestral $\bar{X}$ tiene varianza

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n}$$

(bajo la suposición de una población infinita o, en el caso finito, aplicando la corrección por población finita). El error de muestreo, a menudo representado por el error estándar $SE(\bar{X})$, es:

$$SE(\bar{X}) = \frac{\sigma}{\sqrt{n}}.$$

Claramente, a medida que el tamaño de la muestra n aumenta, $\frac{1}{\sqrt{n}}$ disminuye, lo que implica que el error de muestreo disminuye. Esto demuestra que una mayor muestra conduce a estimaciones más precisas. ■

Exercise 2.2

Explica cómo se calcula la varianza de un estimador y demuestra que es una medida de la precisión del estimador.

Proof. Sea $\hat{\theta}$ un estimador del parámetro θ . La varianza de $\hat{\theta}$ se define como:

$$\text{Var}(\hat{\theta}) = E[(\hat{\theta} - E[\hat{\theta}])^2].$$

Esta cantidad mide la dispersión de las posibles realizaciones de $\hat{\theta}$ alrededor de su valor esperado. Un estimador con varianza pequeña tiende a dar resultados cercanos a su valor esperado en diferentes muestras, lo que se interpreta como mayor precisión. Por otro lado, una alta varianza implica que las estimaciones pueden fluctuar considerablemente, disminuyendo la confiabilidad del estimador. Así, la varianza actúa como una medida de la precisión: a menor varianza, mayor precisión. ■

Exercise 2.3

Sea una población de tamaño N y una muestra aleatoria simple de tamaño n . Demuestra que el estimador de la media muestral es insesgado.

Proof. Sea μ la media poblacional y considere una muestra aleatoria simple $\{X_1, X_2, \dots, X_n\}$. El estimador de la media muestral es:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Utilizando la propiedad de linealidad de la esperanza y la igualdad $E[X_i] = \mu$ para cada i , se tiene:

$$E[\bar{X}] = \frac{1}{n} \sum_{i=1}^n E[X_i] = \frac{1}{n} \cdot n\mu = \mu.$$

Por lo tanto, $E[\bar{X}] = \mu$, lo que demuestra que el estimador $\bar{X}$ es insesgado. ■

Exercise 2.4

Discute cómo la heterogeneidad de una población afecta la selección de una estrategia de muestreo.

Proof. La heterogeneidad se refiere a la variabilidad o diversidad dentro de la población. En poblaciones altamente heterogéneas, los elementos pueden diferir significativamente en sus características. En estos casos, estrategias de muestreo como el muestreo estratificado o por conglomerados son recomendables, ya que permiten dividir la población en subgrupos (estratos o conglomerados) más homogéneos y luego muestrear dentro de ellos. Esto reduce la varianza del estimador al asegurar que se capta la diversidad de la población. En cambio, en poblaciones homogéneas, el muestreo aleatorio simple es generalmente suficiente, ya que la variabilidad interna es baja y cada muestra es representativa de la totalidad. ■

Exercise 2.5

Demuestra que la media poblacional puede ser estimada de forma eficiente utilizando el método de remuestreo (bootstrap).

Proof. El método bootstrap consiste en generar numerosas muestras re-muestreadas (con reemplazo) a partir de la muestra original y calcular la media para cada una de estas muestras. Sea $\bar{X}^*$ la media calculada en una muestra bootstrap. Debido a que cada remuestra se obtiene de la muestra original, la esperanza $E(\bar{X}^*)$ se aproxima a la media muestral $\bar{X}$, la cual es un estimador insesgado de la media poblacional μ . Además, el método bootstrap permite estimar la distribución muestral de $\bar{X}$ y calcular el error estándar de forma no paramétrica. Así, al aprovechar la información contenida en la muestra original, el bootstrap ofrece una estimación eficiente y práctica de la media poblacional. ■

Exercise 2.6

Explora cómo los supuestos del modelo de muestreo afectan la validez de los estimadores.

Proof. Los estimadores se fundamentan en supuestos tales como:

- ❖ **Aleatoriedad e independencia:** Se asume que las observaciones son independientes y que cada unidad tiene la misma probabilidad de ser seleccionada.
- ❖ **Representatividad:** La muestra debe reflejar fielmente las características de la población.
- ❖ **Tamaño de muestra adecuado:** Se supone que el tamaño de la muestra es suficiente para capturar la variabilidad poblacional.

Si estos supuestos se violan, los estimadores pueden ser sesgados o presentar una varianza mayor de lo esperado, comprometiendo la validez de las inferencias. Por ejemplo, la dependencia entre observaciones puede subestimar la varianza, y una muestra no representativa puede llevar a estimaciones sistemáticamente erróneas. En consecuencia, la adherencia a los supuestos del modelo de muestreo es fundamental para la fiabilidad de los estimadores. ■

Exercise 2.7

Analiza los efectos del tamaño poblacional N en la elección entre muestreo con y sin reemplazo.

Proof. Cuando la población es muy grande (N muy grande) y el tamaño de la muestra n es pequeño en comparación, la diferencia entre muestrear con o sin reemplazo es mínima, ya que la probabilidad de seleccionar el mismo elemento repetidamente es despreciable. En este caso, el efecto en la varianza del estimador es prácticamente el mismo.

Sin embargo, en poblaciones pequeñas, el muestreo sin reemplazo es

preferible porque:

- ✿ Evita la selección repetida del mismo elemento, lo que garantiza que se aproveche la totalidad de la información disponible en la población.
- ✿ La varianza del estimador se ajusta mediante el factor de corrección finita $\sqrt{\frac{N-n}{N-1}}$, reduciendo el error de estimación.

Por lo tanto, el tamaño de la población N es un factor determinante en la elección de la técnica de muestreo, ya que influye en la precisión y en la eficiencia de los estimadores. ■

Exercise 2.8

Demuestra matemáticamente que, en una población homogénea, el muestreo aleatorio simple no introduce sesgo en los estimadores.

Proof. En una población homogénea, todos los elementos tienen, o se espera que tengan, características similares. Sea θ un parámetro poblacional (por ejemplo, la media μ) y considere una muestra aleatoria simple $\{X_1, X_2, \dots, X_n\}$. El estimador de la media es:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Dado que cada X_i es extraído con igual probabilidad y la población es homogénea, se tiene $E[X_i] = \mu$ para todo i . Aplicando la linealidad de la esperanza:

$$E[\bar{X}] = \frac{1}{n} \sum_{i=1}^n E[X_i] = \mu.$$

Esto demuestra que $\bar{X}$ es un estimador insesgado de μ , es decir, el muestreo aleatorio simple no introduce sesgo en la estimación de la media en poblaciones homogéneas. ■

Exercise 2.9

Explica cómo el sesgo y la varianza interactúan para determinar el error cuadrático medio de un estimador.

Proof. El error cuadrático medio (ECM) de un estimador $\hat{\theta}$ se define como:

$$ECM(\hat{\theta}) = E[(\hat{\theta} - \theta)^2].$$

Este se puede descomponer en dos componentes:

$$ECM(\hat{\theta}) = (E[\hat{\theta}] - \theta)^2 + \text{Var}(\hat{\theta}),$$

donde:

✿ $(E[\hat{\theta}] - \theta)^2$ es el sesgo al cuadrado.

✿ $\text{Var}(\hat{\theta})$ es la varianza del estimador.

Esta descomposición muestra que un estimador puede tener un ECM bajo si se minimiza tanto el sesgo como la varianza. Un alto sesgo o una alta varianza incrementan el ECM, lo que reduce la precisión del estimador. Así, la interacción entre sesgo y varianza es crucial para determinar la calidad global del estimador. ■

Exercise 2.10

Demuestra que el intervalo de confianza para la media poblacional, calculado a partir de una muestra, se estrecha al aumentar el tamaño de la muestra.

Proof. Un intervalo de confianza para la media poblacional μ se construye usualmente de la forma:

$$\bar{X} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}},$$

donde:

✿ $\bar{X}$ es la media muestral.

✿ $z_{\alpha/2}$ es el valor crítico de la distribución normal para un nivel de confianza $1 - \alpha$.

✿ σ es la desviación estándar poblacional (o una estimación de la misma).

✿ n es el tamaño de la muestra.

El término $\frac{\sigma}{\sqrt{n}}$ es el error estándar y disminuye conforme n aumenta. Por lo tanto, al aumentar n , el margen de error $z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$ se reduce, estrechando el intervalo de confianza y proporcionando una estimación más precisa de μ . ■

Exercise 2.11

Proporciona una demostración teórica del Teorema Central del Límite en el contexto de muestreo.

Proof. Sea $X_1, X_2, \dots, X_n$ una secuencia de variables aleatorias independientes e idénticamente distribuidas (iid) con media $E[X_i] = \mu$ y varianza $\text{Var}(X_i) = \sigma^2 < \infty$. Definimos la media muestral:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

El Teorema Central del Límite (TCL) afirma que la variable estandarizada

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$$

converge en distribución a una normal estándar $N(0, 1)$ cuando $n \rightarrow \infty$, es decir,

$$\lim_{n \rightarrow \infty} P\left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \leq z\right) = \Phi(z),$$

donde $\Phi(z)$ es la función de distribución acumulada de la normal estándar.

1.1. EJERCICIOS PROPUESTOS CHAPTER 2. TÉCNICAS DE MUESTREO

La demostración teórica se fundamenta en la función generadora de momentos (o en el método de cumulantes), demostrando que el MGF de Z converge al MGF de una $N(0, 1)$. Este resultado es esencial en el muestreo, ya que permite aproximar la distribución muestral de la media por una normal, independientemente de la distribución original de la población, siempre que n sea suficientemente grande. ■

Exercise 2.12

Discute las implicaciones prácticas de los supuestos de aleatoriedad en el diseño del muestreo.

Proof. El supuesto de aleatoriedad es fundamental en el diseño de muestreo, ya que:

- ✿ **Representatividad:** Garantiza que cada unidad de la población tenga la misma probabilidad de ser seleccionada, lo que favorece que la muestra sea representativa.
- ✿ **Validez de inferencias:** Permite aplicar técnicas de inferencia estadística, como la construcción de intervalos de confianza y pruebas de hipótesis, basadas en distribuciones teóricas.
- ✿ **Minimización de sesgos:** La aleatoriedad ayuda a prevenir sesgos de selección que podrían distorsionar los resultados y conducir a conclusiones erróneas.

En la práctica, lograr una selección verdaderamente aleatoria puede ser complicado debido a limitaciones logísticas o a la falta de una lista completa de la población. Las desviaciones de la aleatoriedad pueden afectar la precisión y la validez de las estimaciones, por lo que es crucial diseñar y ejecutar el muestreo de manera rigurosa y, en su caso, aplicar técnicas de corrección o ajustar el análisis para mitigar estos problemas. ■

1.1.2 Muestreo Aleatorio

Exercise 2.13

Demuestra que la probabilidad de seleccionar cualquier individuo en un muestreo aleatorio simple es $1/N$, donde N es el tamaño de la población.

Proof. En un muestreo aleatorio simple, se asume que cada uno de los N individuos de la población tiene la misma probabilidad de ser seleccionado. Como la suma de todas las probabilidades debe ser 1, la probabilidad de seleccionar un individuo particular es

$$P(\text{selección de un individuo}) = \frac{1}{N}.$$

Esto se debe a que si se asigna la misma probabilidad a cada uno de los N individuos, entonces

$$\sum_{i=1}^N \frac{1}{N} = \frac{N}{N} = 1.$$

■

Exercise 2.14

Explica cómo se deriva la varianza del estimador de la proporción en un muestreo aleatorio simple.

Proof. Sea p la proporción verdadera de "éxitos" en la población y $\hat{p}$ el estimador muestral de la proporción, definido como

$$\hat{p} = \frac{X}{n},$$

donde X es el número de éxitos en la muestra de tamaño n . Bajo el supuesto de que X sigue una distribución binomial $\text{Bin}(n, p)$, su varianza es

$$\text{Var}(X) = np(1 - p).$$

1.1. EJERCICIOS PROPUESTOS CHAPTER 2. TÉCNICAS DE MUESTREO

Por lo tanto, la varianza de $\hat{p}$ es

$$\text{Var}(\hat{p}) = \text{Var}\left(\frac{X}{n}\right) = \frac{1}{n^2} \text{Var}(X) = \frac{np(1-p)}{n^2} = \frac{p(1-p)}{n}.$$

Si la población es finita y se utiliza el muestreo sin reemplazo, se incorpora la corrección por población finita, quedando

$$\text{Var}(\hat{p}) = \frac{p(1-p)}{n} \cdot \frac{N-n}{N-1}.$$

Esta derivación muestra cómo la varianza del estimador depende tanto de la proporción p como del tamaño de la muestra n (y del tamaño de la población N en el caso finito). ■

Exercise 2.15

Demuestra que la varianza del estimador de la media muestral es menor en un muestreo aleatorio simple con reemplazo que sin reemplazo.

Proof. Consideremos dos escenarios para la estimación de la media poblacional μ :

1. Muestreo con reemplazo: Cada observación es independiente y la varianza de la media muestral es

$$\text{Var}_{\text{con}}(\bar{X}) = \frac{\sigma^2}{n},$$

donde σ^2 es la varianza de la población.

2. Muestreo sin reemplazo: En este caso, se aplica la corrección por población finita y la varianza de la media muestral es

$$\text{Var}_{\text{sin}}(\bar{X}) = \frac{\sigma^2}{n} \cdot \frac{N-n}{N-1}.$$

Dado que para $n \geq 1$ y $N > n$ se cumple que

$$\frac{N-n}{N-1} < 1,$$

se tiene que

$$\text{Var}_{\text{sin}}(\bar{X}) < \frac{\sigma^2}{n} = \text{Var}_{\text{con}}(\bar{X}).$$

Por lo tanto, la varianza del estimador de la media muestral es menor en un muestreo sin reemplazo que en uno con reemplazo. ■

Exercise 2.16

Explora matemáticamente el efecto de un tamaño de muestra insuficiente en la precisión de los estimadores.

Proof. La precisión de un estimador se relaciona inversamente con su varianza. Por ejemplo, para la media muestral, la varianza es

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n},$$

y para la proporción muestral

$$\text{Var}(\hat{p}) = \frac{p(1-p)}{n},$$

(o, incluyendo la corrección por población finita, $\text{Var}(\hat{p}) = \frac{p(1-p)}{n} \cdot \frac{N-n}{N-1}$).

Si el tamaño de muestra n es insuficiente (es decir, pequeño), estas varianzas serán relativamente grandes, lo que implica que los estimadores tenderán a tener alta dispersión alrededor del parámetro verdadero. Esto se traduce en:

- ✿ Un error estándar elevado.
- ✿ Intervalos de confianza más amplios.
- ✿ Menor poder para detectar diferencias o efectos reales.

1.1. EJERCICIOS PROPUESTOS CHAPTER 2. TÉCNICAS DE MUESTREO

En conclusión, un tamaño de muestra insuficiente reduce la precisión y confiabilidad de las inferencias estadísticas. ■

Exercise 2.17

Demuestra que el error estándar de la media disminuye proporcionalmente a $1/\sqrt{n}$ en un muestreo aleatorio simple.

Proof. El error estándar (EE) de la media muestral está dado por la raíz cuadrada de la varianza del estimador de la media:

$$EE(\bar{X}) = \sqrt{\text{Var}(\bar{X})}.$$

En un muestreo aleatorio simple (suponiendo población infinita o aplicando la corrección por población finita de forma despreciable), la varianza es

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n}.$$

Por lo tanto,

$$EE(\bar{X}) = \sqrt{\frac{\sigma^2}{n}} = \frac{\sigma}{\sqrt{n}}.$$

Esto demuestra que el error estándar disminuye en proporción a $1/\sqrt{n}$, es decir, al aumentar el tamaño de la muestra, el error estándar se reduce. ■

Exercise 2.18

Analiza cómo la varianza poblacional afecta la precisión de los estimadores en un muestreo aleatorio.

Proof. La varianza poblacional σ^2 es un componente clave en la varianza de los estimadores. Por ejemplo, para la media muestral se tiene:

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n},$$

y para la proporción muestral (en el caso de poblaciones infinitas o sin la corrección por población finita) se tiene:

$$\text{Var}(\hat{p}) = \frac{p(1-p)}{n}.$$

Una mayor varianza poblacional implica:

- ✿ Mayor dispersión de los datos individuales.
- ✿ Un error estándar más alto para los estimadores, lo que disminuye la precisión de las estimaciones.

Por el contrario, si la varianza poblacional es baja, los datos están más concentrados alrededor de la media y los estimadores serán más precisos. En resumen, la precisión de los estimadores mejora (varianza del estimador disminuye) cuando la varianza poblacional es menor. ■

Exercise 2.19

Sea una muestra aleatoria simple de tamaño n extraída de una población de tamaño N . Deriva el estimador insesgado de la proporción poblacional.

Proof. Sea X el número de individuos con una característica particular en la muestra, y sea p la proporción de la población que posee dicha característica. El estimador de la proporción poblacional se define como

$$\hat{p} = \frac{X}{n}.$$

Para demostrar que es insesgado, calculamos su esperanza:

$$E(\hat{p}) = E\left(\frac{X}{n}\right) = \frac{1}{n}E(X).$$

En un muestreo aleatorio simple, X sigue una distribución hipergeométrica (o

1.1. EJERCICIOS PROPUESTOS CHAPTER 2. TÉCNICAS DE MUESTREO

binomial si la población es muy grande) con esperanza $E(X) = np$. Por lo tanto,

$$E(\hat{p}) = \frac{np}{n} = p.$$

Como $E(\hat{p}) = p$, el estimador es insesgado. ■

Exercise 2.20

Demuestra que el sesgo de un estimador insesgado sigue siendo cero al realizar un muestreo aleatorio.

Proof. Por definición, un estimador $\hat{\theta}$ es insesgado si

$$E(\hat{\theta}) = \theta.$$

El sesgo se define como

$$\text{Sesgo}(\hat{\theta}) = E(\hat{\theta}) - \theta.$$

Para un estimador insesgado, se tiene

$$\text{Sesgo}(\hat{\theta}) = \theta - \theta = 0.$$

Por lo tanto, en cualquier procedimiento de muestreo aleatorio que garantice la aleatoriedad y la representatividad, un estimador insesgado mantiene su sesgo igual a cero. ■

Exercise 2.21

Proporciona un ejemplo teórico donde un muestreo aleatorio sistemático pueda introducir sesgo.

Proof. El muestreo sistemático consiste en seleccionar elementos a intervalos regulares a partir de una lista ordenada. Si la lista tiene una periodicidad que

coincide con el intervalo de selección, se puede introducir un sesgo.

Ejemplo: Supongamos que en una fábrica se produce un lote de 1000 unidades y se ordenan en la secuencia de producción. Si se sabe que cada décima unidad presenta un defecto debido a un problema en el proceso de fabricación, y se realiza un muestreo sistemático seleccionando cada décimo producto, se terminará seleccionando preferentemente las unidades defectuosas. En este caso, el muestreo sistemático introduciría un sesgo al sobreestimar la tasa de defectos, ya que la periodicidad del defecto coincide con el intervalo de muestreo. ■

Exercise 2.22

Explora el impacto de la corrección por población finita en el cálculo de la varianza en un muestreo aleatorio.

Proof. En el muestreo sin reemplazo de una población finita de tamaño N , la varianza del estimador de la media se ajusta con el factor de corrección por población finita (FPC), que es

$$\sqrt{\frac{N-n}{N-1}}.$$

La varianza de la media muestral se expresa como:

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n} \cdot \frac{N-n}{N-1}.$$

El factor $\frac{N-n}{N-1}$ reduce la varianza del estimador en comparación con el caso de muestreo con reemplazo (o población infinita), en el que la varianza es σ^2/n . Este ajuste es especialmente relevante cuando n es una fracción significativa de N . Así, la corrección por población finita mejora la precisión de la estimación al reflejar la disminución de la variabilidad cuando se extraen

Chapter 4 Distribuciones de Probabilidad

1.1 Ejercicios Propuestos

1.1.1 Modelos de Distribución Discreta

Exercise 4.1

Demuestra que la suma de las probabilidades en una distribución discreta es igual a 1.

Proof. Sea X una variable aleatoria discreta con función de masa de probabilidad $p(x)$. Por definición, la función $p(x)$ asigna a cada valor x la probabilidad $P(X = x)$. El conjunto de todos los valores posibles de X se denota por S . La propiedad fundamental de una función de masa de probabilidad es que la suma de las probabilidades sobre todo el espacio muestral es 1, es decir:

$$\sum_{x \in S} p(x) = 1.$$

Esto se deduce de los axiomas de la probabilidad, ya que al considerar la unión de todos los eventos elementales (que son mutuamente excluyentes) se obtiene el espacio muestral completo cuyo valor de probabilidad es 1. ■

Exercise 4.2

Sea $X \sim B(n, p)$. Demuestra que la media de X es $\mu = n \cdot p$.

Proof. Sea X una variable aleatoria con distribución binomial $B(n, p)$, cuya función de masa de probabilidad es:

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad k = 0, 1, 2, \dots, n.$$

La esperanza o media de X se define como:

$$\mathbb{E}[X] = \sum_{k=0}^n k \cdot P(X = k) = \sum_{k=0}^n k \binom{n}{k} p^k (1-p)^{n-k}.$$

Utilizando técnicas de cálculo (por ejemplo, derivando la función generadora de momentos o reconociendo que la suma equivale a np) se llega al resultado:

$$\mathbb{E}[X] = n \cdot p.$$

Otra forma intuitiva de ver este resultado es considerar que X puede verse como la suma de n variables indicadoras independientes X_i (donde $X_i = 1$ si el i -ésimo ensayo es éxito y 0 en caso contrario) con $\mathbb{E}[X_i] = p$. Por la linealidad de la esperanza:

$$\mathbb{E}[X] = \sum_{i=1}^n \mathbb{E}[X_i] = n \cdot p.$$

■

Exercise 4.3

Demuestra que la varianza de $X \sim B(n, p)$ es $\sigma^2 = n \cdot p \cdot (1 - p)$.

Proof. Sea $X \sim B(n, p)$ y recordemos que la varianza se define como:

$$\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2.$$

Como se demostró en el ejercicio anterior, $\mathbb{E}[X] = np$.

Utilizando el hecho de que X puede escribirse como la suma de n variables indicadoras X_i independientes, es decir,

$$X = X_1 + X_2 + \cdots + X_n,$$

y que cada X_i tiene varianza

$$\text{Var}(X_i) = p(1 - p),$$

por la propiedad de la varianza de la suma de variables independientes se tiene:

$$\text{Var}(X) = \sum_{i=1}^n \text{Var}(X_i) = n \cdot p(1 - p).$$

De esta forma, se demuestra que:

$$\sigma^2 = n \cdot p \cdot (1 - p).$$

■

Exercise 4.4

Demuestra que si $X \sim \text{Poisson}(\lambda)$, entonces $\mathbb{E}[X] = \text{Var}(X) = \lambda$.

Proof. Sea X una variable aleatoria con distribución de Poisson de parámetro λ , de modo que:

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k = 0, 1, 2, \dots$$

La esperanza de X se define como:

$$\mathbb{E}[X] = \sum_{k=0}^{\infty} k \cdot \frac{\lambda^k e^{-\lambda}}{k!}.$$

Utilizando propiedades de series (o derivando la función generadora de momentos) se obtiene:

$$\mathbb{E}[X] = \lambda.$$

Para la varianza, se sabe que:

$$\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2.$$

Mediante cálculos similares se demuestra que:

$$\mathbb{E}[X^2] = \lambda + \lambda^2,$$

por lo que:

$$\text{Var}(X) = (\lambda + \lambda^2) - \lambda^2 = \lambda.$$

Así se concluye que:

$$\mathbb{E}[X] = \text{Var}(X) = \lambda.$$



Exercise 4.5

Sea $X \sim \text{Geom}(p)$. Demuestra que $\mathbb{E}[X] = \frac{1}{p}$.

Proof. Consideremos la distribución geométrica en la que X representa el número de ensayos hasta obtener el primer éxito, con función de masa de probabilidad:

$$P(X = k) = p(1 - p)^{k-1}, \quad k = 1, 2, 3, \dots$$

La esperanza de X es:

$$\mathbb{E}[X] = \sum_{k=1}^{\infty} k p (1 - p)^{k-1}.$$

Utilizando la identidad de la serie geométrica derivada, sabemos que:

$$\sum_{k=1}^{\infty} kq^{k-1} = \frac{1}{(1-q)^2}, \quad \text{para } |q| < 1.$$

Con $q = 1 - p$, se tiene:

$$\mathbb{E}[X] = p \cdot \frac{1}{p^2} = \frac{1}{p}.$$

De esta manera se demuestra que:

$$\mathbb{E}[X] = \frac{1}{p}.$$

■

Exercise 4.6

Sea $X \sim \text{Hipergeom}(N, K, n)$. Demuestra que $\mathbb{E}[X] = n \cdot \frac{K}{N}$.

Proof. Sea X el número de éxitos en una muestra de tamaño n extraída sin reemplazo de una población de N elementos, de los cuales K son éxitos. Una forma elegante de demostrar la esperanza es utilizar variables indicadoras. Definamos para $i = 1, 2, \dots, n$ las variables

$$I_i = \begin{cases} 1, & \text{si el } i\text{-ésimo elemento extraído es un éxito,} \\ 0, & \text{en caso contrario.} \end{cases}$$

Entonces, $X = I_1 + I_2 + \dots + I_n$. Por la linealidad de la esperanza,

$$\mathbb{E}[X] = \mathbb{E}[I_1] + \mathbb{E}[I_2] + \dots + \mathbb{E}[I_n].$$

Debido a la simetría del muestreo sin reemplazo, para cualquier i se tiene

$$\mathbb{E}[I_i] = P(\text{éxito en la } i\text{-ésima extracción}) = \frac{K}{N}.$$

Por lo tanto,

$$\mathbb{E}[X] = n \cdot \frac{K}{N}.$$

■

Exercise 4.7

Sea $X \sim \text{BinomNeg}(r, p)$. Demuestra que la probabilidad está dada por:

$$P(X = k) = \binom{k+r-1}{r-1} \cdot p^r \cdot (1-p)^k.$$

Proof. La distribución binomial negativa modela el número de fracasos k antes de obtener el r -ésimo éxito en una secuencia de ensayos independientes con probabilidad de éxito p . Para que ocurra exactamente k fracasos y r éxitos con el r -ésimo éxito en la última posición, se debe cumplir que en los primeros $k+r-1$ ensayos se obtengan exactamente $r-1$ éxitos (y, por lo tanto, k fracasos). El número de formas de distribuir estos $r-1$ éxitos en $k+r-1$ ensayos es

$$\binom{k+r-1}{r-1}.$$

Cada secuencia tiene probabilidad

$$p^{r-1}(1-p)^k,$$

y el último ensayo, que debe ser un éxito, aporta un factor p . Por lo tanto, la probabilidad total es:

$$P(X = k) = \binom{k+r-1}{r-1} p^{r-1}(1-p)^k \cdot p = \binom{k+r-1}{r-1} p^r (1-p)^k.$$

Exercise 4.8

Demuestra que para $X \sim \text{Poisson}(\lambda)$:

$$P(X = k + 1) = \frac{\lambda}{k + 1} \cdot P(X = k).$$

Proof. La función de masa de probabilidad de la distribución de Poisson es

$$P(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}, \quad k = 0, 1, 2, \dots$$

Para $k + 1$ se tiene:

$$P(X = k + 1) = e^{-\lambda} \frac{\lambda^{k+1}}{(k + 1)!}.$$

Dividiendo $P(X = k + 1)$ por $P(X = k)$ se obtiene:

$$\frac{P(X = k + 1)}{P(X = k)} = \frac{e^{-\lambda} \frac{\lambda^{k+1}}{(k+1)!}}{e^{-\lambda} \frac{\lambda^k}{k!}} = \frac{\lambda^{k+1}}{(k + 1)!} \cdot \frac{k!}{\lambda^k} = \frac{\lambda}{k + 1}.$$

Multiplicando ambos lados por $P(X = k)$, se deduce:

$$P(X = k + 1) = \frac{\lambda}{k + 1} \cdot P(X = k).$$

Exercise 4.9

Proporciona una demostración de la aproximación de la distribución binomial a la de Poisson cuando $n \rightarrow \infty$ y $p \rightarrow 0$.

Proof. Sea $X \sim \text{Bin}(n, p)$ con función de masa de probabilidad

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, 2, \dots$$

Se supone que $n \rightarrow \infty$ y $p \rightarrow 0$ de tal forma que $\lambda = np$ se mantiene constante. Para grandes n y pequeño p , se puede aproximar:

$$\binom{n}{k} \approx \frac{n^k}{k!},$$

y

$$p^k = \left(\frac{\lambda}{n}\right)^k.$$

Adicionalmente, usando la aproximación

$$(1-p)^n \approx e^{-np} = e^{-\lambda},$$

y notando que para k pequeño en comparación con n , $(1-p)^{-k}$ es aproximadamente 1, se tiene:

$$(1-p)^{n-k} \approx (1-p)^n \approx e^{-\lambda}.$$

Por lo tanto,

$$P(X = k) \approx \frac{n^k}{k!} \left(\frac{\lambda}{n}\right)^k e^{-\lambda} = \frac{\lambda^k}{k!} e^{-\lambda}.$$

Esta es precisamente la función de masa de probabilidad de la distribución Poisson con parámetro λ , lo que demuestra la aproximación. ■

Exercise 4.10

Sea X una variable aleatoria discreta. Demuestra que $\mathbb{E}[g(X)] = \sum_x g(x) \cdot P(X = x)$, donde $g(x)$ es una función de x .

Proof. La definición de la esperanza de una función $g(X)$ de una variable aleatoria discreta X se establece por el siguiente sumatorio:

$$\mathbb{E}[g(X)] = \sum_{x \in S} g(x) \cdot P(X = x),$$

donde S es el conjunto de valores que X puede tomar. Esta definición surge directamente de la linealidad de la esperanza y es la extensión natural de la definición de esperanza para X (tomando $g(x) = x$). Por lo tanto, la igualdad

$$\mathbb{E}[g(X)] = \sum_x g(x) \cdot P(X = x)$$

es válida por definición de la esperanza de una función de una variable aleatoria discreta. ■

Exercise 4.11

Sea $X \sim \text{Binomial}(n, p)$. Demuestra que:

$$P(X \geq k) = \sum_{i=k}^n \binom{n}{i} p^i (1-p)^{n-i}.$$

Proof. La variable aleatoria X sigue una distribución binomial, por lo que su función de masa de probabilidad viene dada por

$$P(X = i) = \binom{n}{i} p^i (1-p)^{n-i}, \quad \text{para } i = 0, 1, 2, \dots, n.$$

El evento $\{X \geq k\}$ es la unión disjunta de los eventos $\{X = i\}$ para $i = k, k+1, \dots, n$. Por la propiedad de aditividad de eventos mutuamente excluyentes, se tiene:

$$P(X \geq k) = \sum_{i=k}^n P(X = i) = \sum_{i=k}^n \binom{n}{i} p^i (1-p)^{n-i}.$$

■

Exercise 4.12

Demuestra que la distribución geométrica satisface la propiedad de falta de memoria:

$$P(X > x + t \mid X > t) = P(X > x).$$

Proof. Sea X una variable aleatoria con distribución geométrica (ya sea definida sobre $\{1, 2, 3, \dots\}$ o sobre $\{0, 1, 2, \dots\}$). En cualquiera de los casos, se tiene la propiedad de que

$$P(X > k) = (1 - p)^k.$$

Entonces, para $x, t \geq 0$ se cumple que

$$P(X > x+t \mid X > t) = \frac{P(X > x+t)}{P(X > t)} = \frac{(1-p)^{x+t}}{(1-p)^t} = (1-p)^x = P(X > x).$$

Esta relación demuestra la propiedad de falta de memoria de la distribución geométrica. ■

Exercise 4.13

Proporciona un ejemplo de cómo usar la distribución hipergeométrica en un problema de selección de elementos defectuosos.

Proof. Supongamos que en una fábrica se produce un lote de $N = 100$ artículos, de los cuales $K = 10$ son defectuosos. Se seleccionan $n = 15$ artículos al azar sin reemplazo para inspección. Sea X la variable aleatoria que representa el número de artículos defectuosos en la muestra. Entonces, X sigue una distribución hipergeométrica, y su función de masa de probabilidad es:

$$P(X = k) = \frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}}, \quad k = \max(0, n - (N - K)), \dots, \min(n, K).$$

Realizando el cambio de variable

$$u = \frac{x - \mu}{\sigma} \Rightarrow x = \sigma u + \mu, \quad dx = \sigma du,$$

la densidad se transforma en:

$$f(x) dx = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{u^2}{2}\right) du,$$

la cual es la densidad de la normal estándar $Z \sim N(0, 1)$.

Cálculo de la esperanza:

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x f(x) dx = \int_{-\infty}^{\infty} (\sigma u + \mu) \frac{1}{\sqrt{2\pi}} e^{-u^2/2} du.$$

Separando la integral:

$$\mathbb{E}[X] = \sigma \int_{-\infty}^{\infty} u \frac{1}{\sqrt{2\pi}} e^{-u^2/2} du + \mu \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-u^2/2} du.$$

Observamos que:

$$\int_{-\infty}^{\infty} u \frac{1}{\sqrt{2\pi}} e^{-u^2/2} du = 0 \quad (\text{por simetría})$$

y

$$\int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-u^2/2} du = 1.$$

Por lo tanto:

$$\mathbb{E}[X] = \mu.$$

Cálculo de la varianza:

Utilizando la definición:

$$\text{Var}(X) = \mathbb{E}[(X - \mu)^2],$$

y considerando que $X - \mu = \sigma u$, se tiene:

$$\text{Var}(X) = \mathbb{E}[(\sigma u)^2] = \sigma^2 \mathbb{E}[u^2].$$

Sabemos que para la normal estándar:

$$\mathbb{E}[u^2] = 1.$$

Por ello:

$$\text{Var}(X) = \sigma^2.$$

■

Exercise 4.27

Proporciona una demostración matemática de por qué la suma de variables normales independientes sigue una distribución normal.

Proof. Sea $X \sim N(\mu_1, \sigma_1^2)$ y $Y \sim N(\mu_2, \sigma_2^2)$ dos variables aleatorias independientes. Queremos demostrar que la suma

$$Z = X + Y$$

sigue una distribución normal.

Una forma de hacerlo es usando la función generadora de momentos (MGF).

La MGF de una variable normal X es:

$$M_X(t) = \exp\left(\mu_1 t + \frac{\sigma_1^2 t^2}{2}\right),$$

y de igual forma para Y :

$$M_Y(t) = \exp\left(\mu_2 t + \frac{\sigma_2^2 t^2}{2}\right).$$

Dado que X e Y son independientes, la MGF de Z es el producto de las MGFs:

$$M_Z(t) = M_X(t) \cdot M_Y(t) = \exp\left((\mu_1 + \mu_2)t + \frac{(\sigma_1^2 + \sigma_2^2)t^2}{2}\right).$$

Esta es la MGF de una distribución normal con media $\mu_1 + \mu_2$ y varianza $\sigma_1^2 + \sigma_2^2$. Por lo tanto,

$$Z \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2).$$

■

Exercise 4.28

Demuestra que si $X \sim N(\mu, \sigma^2)$, entonces la función de densidad cumple:

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}.$$

Proof. La función de densidad de la distribución normal se define por la propiedad de que la variable aleatoria puede ser expresada como una transformación lineal de una normal estándar. Sea $Z \sim N(0, 1)$ con densidad

$$\phi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}.$$

Si definimos

$$X = \mu + \sigma Z,$$

entonces la transformación inversa es:

$$Z = \frac{X - \mu}{\sigma}.$$

Aplicando la fórmula de cambio de variable para densidades, tenemos:

$$f_X(x) = \phi\left(\frac{x - \mu}{\sigma}\right) \cdot \frac{1}{\sigma} = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right).$$

Esta es la función de densidad de la distribución $N(\mu, \sigma^2)$ tal como se quería demostrar. ■

Exercise 4.29

Proporciona una derivación del intervalo de confianza del 95% para una distribución normal estándar.

Proof. Sea $Z \sim N(0, 1)$. El intervalo de confianza del 95% para Z se define como el intervalo $[-z_{\alpha/2}, z_{\alpha/2}]$ tal que:

$$P(-z_{\alpha/2} \leq Z \leq z_{\alpha/2}) = 0.95.$$

Dado que la distribución normal es simétrica, se tiene:

$$P(Z \leq -z_{\alpha/2}) = 0.025 \quad \text{y} \quad P(Z \leq z_{\alpha/2}) = 0.975.$$

El valor $z_{\alpha/2}$ es el cuantil de orden 0.975 de la normal estándar. Usualmente se conoce que:

$$z_{0.975} \approx 1.96.$$

Por lo tanto, el intervalo de confianza del 95% es:

$$[-1.96, 1.96].$$

Este resultado se utiliza como base para construir intervalos de confianza en muestras grandes cuando se asume normalidad. ■

Exercise 4.30

Sea $X \sim \text{Gamma}(\alpha, \beta)$. Demuestra que $\mathbb{E}[X] = \alpha \cdot \beta$.

Proof. La función de densidad de la distribución Gamma, con parámetro de forma α y parámetro de escala β , es:

$$f(x) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta}, \quad x > 0.$$

La esperanza se define como:

$$\mathbb{E}[X] = \int_0^\infty x f(x) dx = \frac{1}{\Gamma(\alpha)\beta^\alpha} \int_0^\infty x^\alpha e^{-x/\beta} dx.$$

Realizamos el cambio de variable:

$$u = \frac{x}{\beta} \Rightarrow x = \beta u, \quad dx = \beta du.$$

Sustituyendo en la integral:

$$\mathbb{E}[X] = \frac{1}{\Gamma(\alpha)\beta^\alpha} \int_0^\infty (\beta u)^\alpha e^{-u} \beta du = \frac{\beta^{\alpha+1}}{\Gamma(\alpha)\beta^\alpha} \int_0^\infty u^\alpha e^{-u} du.$$

Simplificando:

$$\mathbb{E}[X] = \frac{\beta}{\Gamma(\alpha)} \Gamma(\alpha + 1).$$

Utilizando la propiedad de la función Gamma:

$$\Gamma(\alpha + 1) = \alpha \Gamma(\alpha),$$

obtenemos:

$$\mathbb{E}[X] = \beta \alpha = \alpha \cdot \beta.$$

■

Exercise 4.31

Demuestra que si $X_1, X_2, \dots, X_n$ son independientes y $X_i \sim \text{Exponencial}(\lambda)$, entonces $\sum_{i=1}^n X_i \sim \text{Gamma}(n, \frac{1}{\lambda})$.

Proof. Recordemos que la función de densidad de la variable exponencial es

$$f_{X_i}(x) = \lambda e^{-\lambda x}, \quad x \geq 0.$$

Esta densidad puede escribirse en forma de densidad Gamma con parámetros de forma $\alpha = 1$ y escala $\beta = \frac{1}{\lambda}$, pues

$$f_{X_i}(x) = \frac{1}{\beta \Gamma(1)} x^{1-1} e^{-x/\beta} = \frac{1}{\beta} e^{-x/\beta}.$$

Dado que la suma de variables independientes con distribución Gamma, todas con el mismo parámetro de escala β , es una variable Gamma con forma igual a la suma de las formas, tenemos que:

$$\sum_{i=1}^n X_i \sim \text{Gamma}(1 + 1 + \dots + 1, \beta) = \text{Gamma}(n, \frac{1}{\lambda}).$$

Alternativamente, usando la función generadora de momentos (MGF), la MGF de X_i es

$$M_{X_i}(t) = \frac{\lambda}{\lambda - t}, \quad t < \lambda.$$

Por la independencia,

$$M_S(t) = \prod_{i=1}^n M_{X_i}(t) = \left(\frac{\lambda}{\lambda - t} \right)^n,$$

la cual coincide con la MGF de una variable Gamma con parámetros $\alpha = n$ y $\beta = \frac{1}{\lambda}$ (recordando que la MGF de una Gamma es $(1 - \beta t)^{-\alpha}$ para $t < 1/\beta$).

Esto concluye la demostración. ■

Exercise 4.32

Demuestra que la función generadora de momentos de $X \sim \text{Exponencial}(\lambda)$ es:

$$M_X(t) = \frac{\lambda}{\lambda - t}, \quad t < \lambda.$$

Proof. La función generadora de momentos (MGF) se define como

$$M_X(t) = \mathbb{E}[e^{tX}] = \int_0^{\infty} e^{tx} f_X(x) dx.$$

Con la densidad de la exponencial,

$$f_X(x) = \lambda e^{-\lambda x}, \quad x \geq 0,$$

obtenemos

$$M_X(t) = \lambda \int_0^{\infty} e^{tx} e^{-\lambda x} dx = \lambda \int_0^{\infty} e^{-(\lambda-t)x} dx.$$

La integral converge para $t < \lambda$ y se evalúa como

$$\int_0^{\infty} e^{-(\lambda-t)x} dx = \frac{1}{\lambda - t}.$$

Por lo tanto,

$$M_X(t) = \frac{\lambda}{\lambda - t}, \quad t < \lambda.$$

■

Exercise 4.33

Proporciona una demostración de la relación entre las distribuciones exponencial y gamma.

Proof. La distribución Gamma con parámetros de forma α y escala β tiene la función de densidad

$$f_X(x) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta}, \quad x > 0.$$

Cuando tomamos $\alpha = 1$, notamos que

$$\Gamma(1) = 1,$$

y la densidad se reduce a

$$f_X(x) = \frac{1}{\beta} e^{-x/\beta}, \quad x > 0.$$

Si definimos $\lambda = \frac{1}{\beta}$, obtenemos

$$f_X(x) = \lambda e^{-\lambda x}, \quad x > 0,$$

que es precisamente la función de densidad de una variable exponencial con parámetro λ . Así, la distribución exponencial es un caso particular de la distribución Gamma cuando $\alpha = 1$. ■

Exercise 4.34

Sea $X \sim N(0, 1)$. Demuestra que la probabilidad acumulativa $\Phi(x)$ satisface:

$$\Phi(-x) = 1 - \Phi(x).$$

Proof. La función de distribución acumulativa (CDF) de la normal estándar es

$$\Phi(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt.$$

1.1. EJERCICIOS PROPUESTOS CHAPTER 4. DISTRIBUCIONES DE PROBABILIDAD

Por la simetría de la función de densidad, que es una función par ($e^{-t^2/2} = e^{-(t)^2/2}$), se tiene que

$$\Phi(-x) = \int_{-\infty}^{-x} \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt.$$

Realizando el cambio de variable $u = -t$ (de donde $du = -dt$), los límites se transforman: cuando $t = -\infty$, $u = \infty$ y cuando $t = -x$, $u = x$. Así,

$$\Phi(-x) = \int_{\infty}^x \frac{1}{\sqrt{2\pi}} e^{-u^2/2} (-du) = \int_x^{\infty} \frac{1}{\sqrt{2\pi}} e^{-u^2/2} du.$$

Por definición,

$$1 - \Phi(x) = \int_x^{\infty} \frac{1}{\sqrt{2\pi}} e^{-u^2/2} du.$$

De donde se sigue que

$$\Phi(-x) = 1 - \Phi(x).$$

■

Exercise 4.35

Proporciona una derivación matemática para la varianza de $X \sim \text{Gamma}(\alpha, \beta)$:

$$\text{Var}(X) = \alpha \cdot \beta^2.$$

Proof. Para $X \sim \text{Gamma}(\alpha, \beta)$, se conoce que el k -ésimo momento es

$$\mathbb{E}[X^k] = \beta^k \frac{\Gamma(\alpha + k)}{\Gamma(\alpha)}.$$

En particular, la esperanza es:

$$\mathbb{E}[X] = \beta \frac{\Gamma(\alpha + 1)}{\Gamma(\alpha)} = \alpha\beta,$$

ya que $\Gamma(\alpha + 1) = \alpha \Gamma(\alpha)$.

El segundo momento es:

$$\mathbb{E}[X^2] = \beta^2 \frac{\Gamma(\alpha + 2)}{\Gamma(\alpha)} = \beta^2 \frac{(\alpha + 1)\alpha \Gamma(\alpha)}{\Gamma(\alpha)} = \beta^2 \alpha(\alpha + 1).$$

La varianza se obtiene como

$$\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = \beta^2 \alpha(\alpha + 1) - (\alpha\beta)^2.$$

Simplificando,

$$\text{Var}(X) = \beta^2 \alpha(\alpha + 1 - \alpha) = \beta^2 \alpha.$$

Por lo tanto,

$$\text{Var}(X) = \alpha \cdot \beta^2.$$

■

Exercise 4.36

Proporciona un ejemplo práctico del uso de la distribución gamma en el modelado de tiempos de espera.

Proof. Un ejemplo práctico del uso de la distribución gamma es en el modelado del tiempo total de espera para que ocurran n eventos en un sistema de colas. Supongamos que en un centro de llamadas, los tiempos entre la llegada de llamadas se modelan mediante una distribución exponencial con parámetro λ . Dado que la suma de n variables exponenciales independientes con el mismo parámetro λ tiene distribución Gamma con parámetros de forma $\alpha = n$ y de escala $\beta = \frac{1}{\lambda}$, el tiempo total de espera para recibir n llamadas se distribuye como

$$T = \sum_{i=1}^n X_i \sim \text{Gamma}\left(n, \frac{1}{\lambda}\right).$$

Este modelo es útil para predecir, por ejemplo, cuánto tiempo en promedio tardará en llegar la n -ésima llamada, lo que puede ayudar a dimensionar re-

cursos y optimizar la atención al cliente. ■

Exercise 4.37

Demuestra que si $X \sim N(\mu, \sigma^2)$, entonces $Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$.

Proof. Sea $X \sim N(\mu, \sigma^2)$ con función de densidad

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right), \quad x \in \mathbb{R}.$$

Definimos la variable estandarizada

$$Z = \frac{X - \mu}{\sigma}.$$

Para encontrar la función de densidad de Z , realizamos el cambio de variable inverso:

$$x = \sigma z + \mu, \quad dx = \sigma dz.$$

La densidad de Z es:

$$f_Z(z) = f_X(\sigma z + \mu) \cdot \left| \frac{dx}{dz} \right| = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(\sigma z)^2}{2\sigma^2}\right) \cdot \sigma.$$

Simplificando:

$$f_Z(z) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{z^2}{2}\right),$$

que es la densidad de la distribución normal estándar $N(0, 1)$. Por lo tanto,

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1).$$

■

Exercise 4.38

Sea $X \sim \text{Gamma}(\alpha, \beta)$. Proporciona una demostración matemática de que la suma de n variables gamma independientes es también una variable gamma.

Proof. Sea $X_1, X_2, \dots, X_n$ variables aleatorias independientes, donde cada $X_i \sim \text{Gamma}(\alpha_i, \beta)$ comparte el mismo parámetro de escala β (esto es importante para que la suma tenga una distribución Gamma). La función de densidad de cada X_i es

$$f_{X_i}(x) = \frac{1}{\Gamma(\alpha_i)\beta^{\alpha_i}} x^{\alpha_i-1} e^{-x/\beta}, \quad x > 0.$$

La función generadora de momentos (MGF) de X_i es

$$M_{X_i}(t) = (1 - \beta t)^{-\alpha_i}, \quad t < \frac{1}{\beta}.$$

Debido a la independencia, la MGF de la suma $S = \sum_{i=1}^n X_i$ es:

$$M_S(t) = \prod_{i=1}^n M_{X_i}(t) = \prod_{i=1}^n (1 - \beta t)^{-\alpha_i} = (1 - \beta t)^{-\sum_{i=1}^n \alpha_i}.$$

Esta MGF corresponde a la de una variable Gamma con parámetros de forma $\alpha = \sum_{i=1}^n \alpha_i$ y escala β . En el caso particular en que $\alpha_i = \alpha$ para todo i , se tiene:

$$S \sim \text{Gamma}(n\alpha, \beta).$$

Por lo tanto, la suma de variables Gamma independientes (con el mismo parámetro de escala) es también una variable Gamma. ■

Exercise 4.39

Demuestra que para $X \sim \text{Beta}(\alpha, \beta)$, la media está dada por:

$$\mathbb{E}[X] = \frac{\alpha}{\alpha + \beta}.$$

Proof. La función de densidad de la distribución Beta es

$$f_X(x) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1}(1-x)^{\beta-1}, \quad 0 < x < 1.$$

La esperanza de X es

$$\mathbb{E}[X] = \int_0^1 x f_X(x) dx = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \int_0^1 x^\alpha (1-x)^{\beta-1} dx.$$

Observamos que la integral

$$\int_0^1 x^\alpha (1-x)^{\beta-1} dx$$

es la definición de la función Beta $B(\alpha + 1, \beta)$, es decir,

$$\int_0^1 x^\alpha (1-x)^{\beta-1} dx = \frac{\Gamma(\alpha + 1)\Gamma(\beta)}{\Gamma(\alpha + \beta + 1)}.$$

Sustituyendo en la expresión de la esperanza, tenemos:

$$\mathbb{E}[X] = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \cdot \frac{\Gamma(\alpha + 1)\Gamma(\beta)}{\Gamma(\alpha + \beta + 1)} = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha + \beta + 1)} \cdot \frac{\Gamma(\alpha + 1)}{\Gamma(\alpha)}.$$

Utilizando la propiedad $\Gamma(\alpha + 1) = \alpha \Gamma(\alpha)$ y $\Gamma(\alpha + \beta + 1) = (\alpha + \beta)\Gamma(\alpha + \beta)$,

se obtiene:

$$\mathbb{E}[X] = \frac{\alpha}{\alpha + \beta}.$$

■

Parte III

Análisis Bivariado y Variables Aleatorias

Chapter 5 Distribuciones Bivariadas

1.1 Ejercicios Propuestos

1.1.1 Tablas Estadísticas Bidimensionales

Exercise 5.1

Construye una tabla de contingencia para un conjunto de datos bidimensionales y calcula las probabilidades marginales y conjuntas.

Proof. Consideremos un ejemplo práctico basado en una encuesta sobre la preferencia de bebida y el género. Sean las variables:

X : Género (Masculino, Femenino) y Y : Preferencia de bebida (Café, Té).

Supongamos que se obtuvieron los siguientes datos:

Género / Bebida	Café	Té	Total
Masculino	20	30	50
Femenino	25	25	50
Total	45	55	100

Las probabilidades conjuntas se calculan dividiendo cada frecuencia por el total (100). Por ejemplo:

$$P(\text{Masculino, Café}) = \frac{20}{100} = 0.20, \quad P(\text{Masculino, Té}) = \frac{30}{100} = 0.30,$$

$$P(\text{Femenino, Café}) = \frac{25}{100} = 0.25, \quad P(\text{Femenino, Té}) = \frac{25}{100} = 0.25.$$

Las probabilidades marginales se obtienen sumando las probabilidades

1.1. EJERCICIOS PROPUESTOS CHAPTER 5. DISTRIBUCIONES BIVARIADAS

conjuntas a lo largo de filas o columnas. Por ejemplo:

$$P(\text{Masculino}) = \frac{50}{100} = 0.50, \quad P(\text{Femenino}) = \frac{50}{100} = 0.50,$$

$$P(\text{Café}) = \frac{45}{100} = 0.45, \quad P(\text{Té}) = \frac{55}{100} = 0.55.$$

De esta forma, hemos construido una tabla de contingencia y calculado las probabilidades marginales y conjuntas. ■

Exercise 5.2

Demuestra que la suma de las probabilidades conjuntas en una tabla bidimensional es igual a 1.

Proof. Sea $\{p_{ij}\}$ la tabla de probabilidades conjuntas de dos variables discretas X e Y , donde i recorre las categorías de X y j las de Y . Por definición de función de masa de probabilidad conjunta, se tiene:

$$\sum_i \sum_j p_{ij} = 1.$$

Esto se debe a que la suma de las probabilidades de todos los posibles eventos en el espacio muestral debe ser 1. En el ejemplo anterior, sumando las probabilidades:

$$0.20 + 0.30 + 0.25 + 0.25 = 1.00.$$

Por lo tanto, la suma de las probabilidades conjuntas en una tabla bidimensional es igual a 1. ■

Exercise 5.3

Proporciona un ejemplo teórico y calcula las probabilidades condicionadas utilizando una tabla de contingencia.

Proof. Utilicemos nuevamente el ejemplo de la tabla de contingencia sobre Género y Preferencia de bebida:

Género / Bebida	Café	Té	Total
Masculino	20	30	50
Femenino	25	25	50
Total	45	55	100

Calculemos algunas probabilidades condicionadas:

1. La probabilidad de que una persona prefiera Café dado que es Masculino:

$$P(\text{Café} \mid \text{Masculino}) = \frac{P(\text{Masculino, Café})}{P(\text{Masculino})} = \frac{20/100}{50/100} = \frac{20}{50} = 0.40.$$

2. La probabilidad de que una persona sea Femenina dado que prefiere Té:

$$P(\text{Femenino} \mid \text{Té}) = \frac{P(\text{Femenino, Té})}{P(\text{Té})} = \frac{25/100}{55/100} = \frac{25}{55} \approx 0.455.$$

3. La probabilidad de que una persona prefiera Té dado que es Femenina:

$$P(\text{Té} \mid \text{Femenino}) = \frac{25/100}{50/100} = \frac{25}{50} = 0.50.$$

Estos cálculos muestran cómo se utilizan los datos de una tabla de contingencia para obtener probabilidades condicionadas. ■

Exercise 5.4

Demuestra que si dos variables son independientes, la probabilidad conjunta es el producto de las probabilidades marginales.

Proof. Sea X e Y dos variables aleatorias discretas. Por definición, X e Y son

independientes si para todo par de valores x e y se cumple:

$$P(X = x, Y = y) = P(X = x) \cdot P(Y = y).$$

Esta propiedad es la definición misma de independencia. En el contexto de una tabla de contingencia, si los datos indican que cada celda p_{ij} satisface

$$p_{ij} = p_{i\cdot} \cdot p_{\cdot j},$$

donde $p_{i\cdot}$ y $p_{\cdot j}$ son las probabilidades marginales de X e Y respectivamente, entonces se concluye que X e Y son independientes. Por lo tanto, la probabilidad conjunta es efectivamente el producto de las probabilidades marginales.



Exercise 5.5

Proporciona una demostración matemática para verificar la independencia estadística entre dos variables categóricas utilizando una tabla bidimensional.

Proof. Consideremos dos variables categóricas X e Y y una tabla de contingencia con probabilidades conjuntas $p_{ij} = P(X = x_i, Y = y_j)$ y marginales

$$p_{i\cdot} = \sum_j p_{ij} \quad \text{y} \quad p_{\cdot j} = \sum_i p_{ij}.$$

Las variables X e Y son independientes si y solo si, para todo i y j ,

$$p_{ij} = p_{i\cdot} \cdot p_{\cdot j}.$$

Para verificar la independencia utilizando la tabla, se procede de la siguiente manera:

1. Calcular las probabilidades marginales $p_{i\cdot}$ y $p_{\cdot j}$ a partir de la tabla.
2. Para cada celda, comparar el valor observado p_{ij} con el producto $p_{i\cdot} \cdot p_{\cdot j}$.

Si se verifica que

$$p_{ij} = p_{i\cdot} \cdot p_{\cdot j} \quad \text{para todo } i, j,$$

entonces se concluye matemáticamente que X e Y son independientes.

Por ejemplo, si en una celda de la tabla se tiene $p_{ij} = 0.20$, y las probabilidades marginales correspondientes son $p_{i\cdot} = 0.50$ y $p_{\cdot j} = 0.40$, se debe cumplir:

$$0.20 \stackrel{?}{=} 0.50 \times 0.40 = 0.20.$$

Si este igual se verifica en todas las celdas, se confirma la independencia estadística entre X e Y . ■

Exercise 5.6

Demuestra que las frecuencias relativas en una tabla bidimensional pueden interpretarse como probabilidades conjuntas.

Proof. Sea una tabla de contingencia con frecuencias absolutas n_{ij} en cada celda, donde i y j denotan las categorías de dos variables X e Y , respectivamente. El total de observaciones es

$$N = \sum_i \sum_j n_{ij}.$$

Las frecuencias relativas se definen como

$$p_{ij} = \frac{n_{ij}}{N}.$$